

机器学习的流程

机器学习流程通常包括五个步骤(图 1-2):





图 1-2 机器学习流程。从左到右：我们必须深入了解问题领域，获取并深入理解数据，进行特征工程(显然是本书的主要关注点)，选择并训练模型，然后在部署模型时要明白，如果模型评估显示任何形式的数据或概念漂移，我们可能需要回溯到过去的每一步，因为这可能是模型衰减的表现——随着时间推移，机器学习模型性能下降

特征工程的定义

特征工程（Feature Engineering）是机器学习与数据挖掘中的核心环节，指利用领域知识、数学和统计方法，对原始数据进行提取、构造、转换和选择，将其转化为适合机器学习模型训练的特征（变量）的过程。

把原始数据变成模型能更好使用的特征。


传统机器学习判别物体类别



特征工程的定义

特征工程（Feature Engineering）是机器学习与数据挖掘中的核心环节，指利用领域知识、数学和统计方法，对原始数据进行提取、构造、转换和选择，将其转化为适合机器学习模型训练的特征（变量）的过程。

把原始数据变成模型能更好使用的特征。



特征工程的重要性

数据和特征决定了机器学习的上限，而模型和算法只是逼近这个上限。


好的特征：即使使用一个简单的线性模型，也能获得很不错的效果。它让问题变得更简单。

坏的特征：即使使用最先进的、最复杂的模型（如XGBoost、深度神经网络），效果也可能很差。垃圾进，垃圾出（Garbage in, garbage out）

特征工程带来哪些好处

- 提升模型准确率、AUC、F1、RMSE等指标；
- 降低过拟合，提高泛化能力；
- 减少训练时间和计算资源；
- 降低维度，缓解维度灾难；
- 简化模型结构，便于解释和部署；
- 增强模型对缺失、异常、分布变化的鲁棒性；
- 让模型更容易结合业务规则和领域知识；
- 提高线上效果和可维护性。

特征工程包括哪些内容



时序特征特征提取

1. 对四季和月份进行编码

对四季进行编码。

1. One-hot 编码：最稳妥的默认方案

春、夏、秋、冬各一列：

季节	春	夏	秋	冬
春	1	0	0	0
夏	0	1	0	0
秋	0	0	1	0
冬	0	0	0	1

时序特征特征提取

1. 对四季和月份进行编码

对月份进行编码。

1. 首选: sin/cos 年周期编码

对月份 $m = 1, 2, \dots, 12$:

$$s = \sin\left(\frac{2\pi m}{12}\right), \quad c = \cos\left(\frac{2\pi m}{12}\right)$$

这样 12 月和 1 月在圆上相邻, 不会出现“12 很大、1 很小”的断裂。

1 个月份变量, 变成 2 个连续特征

时序特征特征提取

2. 滞后特征

时间序列的过去值作为新的特征，以揭示序列的自相关性质。

例如，可以使用前一天（滞后1）或前一周（滞后7）的数据作为预测当前值的特征。

具体地，利用第 $t-n, \dots, t-1$ 天的降水和径流预测第 t 天的径流。

时序特征特征提取

3. 滚动窗口特征

计算时间窗口内的统计量，如平均值、中位数、标准偏差、最小值和最大值。这些统计量可以捕捉到时间序列在不同时间段的行为变化。

滚动窗口特征使用过去一段时间的数据，在一个窗口（时间范围）内计算一个统计量，将其作为当前时间戳的特征。

例如，一个30分钟滞后特征只是获取30分钟前的值并将其作为特征，而一个30分钟滚动窗口特征将获取过去30分钟内的所有值，并做统计，将统计值作为特征。

特征缩放（特征归一化、标准化）

1.归一化的定义与目的

归一化是特征工程中常用的数据处理的方法，它的定义是：将有量纲的表达式，经过线性变换，化为无量纲的表达式，成为标量。这样做目的是为了**消除指标之间量纲的影响，以解决数据指标之间的可比性。**

因此，归一化的本质就是解决变量间不具可比性的问题，**原始数据归一化后各指标处于同一数量级，适合进行综合对比评价。**

归一化：把每个特征向量的值都缩放到相同数值范围，如 $[0, 1]$ 或 $[-1, 1]$ 。

特征间的单位（尺度）可能不同，为了消除特征间单位和尺度差异的影响，便于特征之间的比较，需要对特征进行归一化。

特征缩放（特征归一化、标准化）

1. 归一化的定义与目的

数据各个特征变量的量纲差异很大，可以使用数据标准化消除不同分量量纲差异的影响，加速模型收敛的效率。

归一化消除样本不同属性具有不同量级时的影响：



- ①数量级的差异将导致量级较大的属性占据主导地位；
- ②数量级的差异将导致迭代收敛速度减慢；
- ③依赖于样本距离的算法对于数据的数量级非常敏感。

特征缩放（特征归一化、标准化）

2. 归一化的好处

(1) 归一化后加快了梯度下降法求最优解的速度。

(2) 归一化有可能提高精度。



特征缩放（特征归一化、标准化）

3.归一化的常用方法

最大 - 最小规范化：可以将所有特征值压缩（或拓展）到[0,1]区间

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

Z-Score标准化：将所有特征值缩放到均值为0、标注差为1的分布上。

$$x' = \frac{x - \mu}{\sigma}$$

如果初始特征服从高斯分布，缩放后的特征也符合高斯分布。

最大-最小规范化不能很好地处理异常值，异常值会使特征值集中到一个狭窄的区间，而**零均值标准化**对异常值的鲁棒性强，在许多情况下，它优于**最大-最小规范化**。

特征缩放（特征归一化、标准化）

4.哪些方法需要归一化？

需要使用梯度下降的模型要做归一化，因为不做归一化会使收敛的路径呈Z字型下降，导致收敛路径太慢，而且不容易找到最优解，归一化之后加快了梯度下降求最优解的速度，并有可能提高精度。比如说线性回归、逻辑回归、adaboost、xgboost、GBDT、SVM、NeuralNetwork等。

需要计算距离的模型需要做归一化，比如说KNN、KMeans等。

与距离计算无关的**概率模型**，不需要归一化，比如朴素贝叶斯；

与距离计算无关的**基于树的模型**，不需要归一化，比如决策树、随机森林等，树中节点的选择只关注当前特征在哪里切分对分类更好，即只在意特征内部的相对大小，而与特征间的相对大小无关。

特征缩放（特征归一化、标准化）

4.哪些方法需要归一化?

[illegible]

特征缩放（特征归一化、标准化）

5.归一化的几个需要注意的点

不论使用何种缩放方法，特征缩放总是将特征除以一个常数（归一化常数），因此归一化不会改变单特征分布的形状。

通常，我们说的归一化是面向训练集中所有实例的。在训练集上计算出归一化参数后，就可以运行时应用了（也可以用于测试集）。

在训练集上计算出的参数应该是固定不变的，它在测试集上可能会生成要求范围之外的结果。

在测试集上重新计算参数，这样做会使算法在实际当中得到错误的结果。对测试集独立归一化是常见错误之一！

特征选择

常用的特征选择方法有：

Filter：过滤法，按照发散性或者相关性对各个特征进行评分，设定阈值或者待选择阈值的个数，选择特征。

Wrapper：包装法，根据目标函数（通常是预测效果评分），每次选择若干特征，或者排除若干特征。

Embedded：嵌入法，先使用某些机器学习的算法和模型进行训练，得到各个特征的权值系数，根据系数从大到小选择特征。

特征选择

1. 过滤式 (Filter)

思路：不依赖任何机器学习模型，直接用统计指标给每个特征打分，再筛选得分高的特征。

特点：速度快、可扩展性好，适合高维数据初筛；但只看单特征与目标的关系，忽略特征组合和模型偏好。

常见方法：

- **方差阈值：** `VarianceThreshold`，删除方差极低的特征。
- **卡方检验：** `chi2`，适用于分类任务，要求特征非负。
- **互信息：** `mutual_info_classif` / `mutual_info_regression`，能捕捉非线性关系。
- **F 检验：** `f_classif` / `f_regression`，ANOVA F 值。
- **相关系数：**皮尔逊、斯皮尔曼相关系数。
- **信息增益 / 基尼指数：**常用于文本分类等。
- **Relief / ReliefF：**基于近邻的特征权重。
- **mRMR：**最小冗余最大相关，兼顾相关性和冗余度。

优点：计算快，独立于模型，适合初步筛选。

缺点：可能保留冗余特征，忽略特征间交互，选出的特征不一定对特定模型最优。

特征选择

2. 包裹式 (Wrapper)

思路：把特征子集选择看作搜索问题，用具体模型的性能来评价特征子集好坏。

特点：直接优化模型表现，通常效果较好；但计算成本高，容易过拟合验证集，需要交叉验证。

常见方法：

- **前向选择：**从空集开始，每次加入一个最优特征。
- **后向消除：**从全部特征开始，每次删除一个最差特征。
- **双向搜索：**前向和后向结合。
- **递归特征消除 RFE / RFECV：**反复训练模型，删除重要性最低的特征；RFECV 用交叉验证选最优特征数。
- **穷举搜索：**遍历所有子集，特征多时不可行。
- **启发式搜索：**遗传算法、粒子群优化等。
- **Boruta：**基于随机森林和“影子特征”比较，判断特征是否显著重要。

优点：考虑特征组合和模型交互，通常能获得更好的预测性能。

缺点：计算量大，特征多时很慢；若调参或评估不当，容易过拟合。

特征选择

3. 嵌入式 (Embedded)

思路：特征选择发生在模型训练过程中，由模型自身机制完成。

特点：介于过滤式和包裹式之间，兼顾效果和计算效率；但依赖具体模型和正则化参数。

常见方法：

- **L1 正则化：**Lasso、L1 逻辑回归、L1 SVM，会产生稀疏系数，使部分特征权重为 0。
- **弹性网络 Elastic Net：**结合 L1 和 L2，适合相关特征较多的情况。
- **树模型特征重要性：**决策树、随机森林、GBDT、XGBoost、LightGBM 等。
- **SelectFromModel：**根据模型系数或重要性阈值选择特征。
- **贝叶斯正则化 / ARD：**自动相关性确定，稀疏化特征权重。
- **正则化回归：**如 LassoCV、LogisticRegressionCV。

优点：训练中自动选择，效率较高，能考虑特征交互。

缺点：依赖模型假设；Lasso 在强相关特征中可能随机保留一个；树模型重要性对高基数、连续特征有偏好。